

Вступ до курсу ML


Ступак Денис

План:


- Що таке AI, ML, DL?
- Хто такий ML інженер?
- Словник термінів
- Типи задач
- Шлях навчання




Що таке AI, ML, DL?




A Brief History of AI with Deep Learning



McCulloch-Pitts




Rosenblatt




Widrow-Hoff


Minsky-Papert



Rumelhart, Hinton et al.




LeCun




Hinton-Ruslan

Krizhevsky et al.

Vaswani



How Is This Era of AI Different?



Just as electricity transformed almost everything 100 years ago, today I actually have a hard time thinking of an industry that I don't think AI will transform in the next several years.

Andrew Ng




<https://www.youtube.com/watch?v=21EiKfQYZXc>

Темпи зростання кількості інформації

Worldwide data creation 2010-2027 (in zettabytes)

Volume of information created and consumed globally to reach 147 zettabytes (ZB) in 2024 forecast by IDC with continued growth through 2027.




Based on forecast and compound annual growth rate identified by source.

Chart: CBL Data Recovery/Platter Chatter • Source: IDC DataAge 2025; IDC Worldwide Global DataSphere Forecast, 2023–2027 • Created with [Datawrapper](#)

Визначення AI


Штучний інтелект (Artificial intelligence, AI) — це напрямок в інформатиці та інформаційних технологіях, завданням якого є відтворення за допомогою обчислювальних систем та інших штучних пристроїв розумних міркувань і дій.

“A program that can sense, reason, act, and adapt.” (Intel)



Визначення ML

Маші́нне навча́ння (МН, англ. machine learning, ML) — це галузь досліджень штучного інтелекту, зосереджена на розробці та вивченні статистичних алгоритмів[en], здатних навчатися з даних і узагальнюватися на небачені дані, й відтак виконувати завдання без явних інструкцій.




Machine Learning

These programs learn from repeatedly seeing data, rather than being explicitly programmed by humans.



Machine Learning

“The study and construction of programs that are *not explicitly programmed*, but learn patterns as they are exposed to more data over time.” (Intel)




Визначення DL

Глибоке навчання – це підмножина машинного навчання, яке є галуззю штучного інтелекту (ШІ).

Вона передбачає використання нейронних мереж із кількома шарами для аналізу та навчання на основі великої кількості даних.





Різниця між роботою класичних алгоритмів і DL

Deep Learning Example

Classic Machine Learning

Step 1: Determine features.
Step 2: Feed them through model.



Feature Detection

Machine Learning Classifier Algorithm


"Arjun"

Deep Learning

Steps 1 and 2 are combined into 1 step.




Neural Network



"Arjun"

Хто такий ML інженер?

	Data Analyst	Machine Learning Engineer	Data Engineer	Data Scientist
Programming Tools	Very important	Very important	Very important	Very important
Data Visualization and Communication	Very important	Somewhat important	Somewhat important	Very important
Data Intuition	Somewhat important	Very important	Somewhat important	Very important
Statistics	Somewhat important	Very important	Somewhat important	Very important
Data Wrangling	Not that important	Not that important	Very important	Very important
Machine Learning	Not that important	Very important	Not that important	Very important
Software Engineering	Not that important	Somewhat important	Very important	Somewhat important
Multivariable Calculus and Linear Algebra	Not that important	Very important	Not that important	Somewhat important
Not that important Somewhat important Very important				



Data Scientist

- Identify use cases
- Data selection and processing
- Model building




ML Engineer

- Production-ready code
- Design architecture
- Scaling and feedback loop

Gartner, 2020

ML ENGINEER ROADMAP



Machine Learning Roadmap







Схема роботи із даними



Крок 1




ML проект завжди має розроблятись в контексті клієнта

Робота має початись із постановки завдання

В завданні має бути описано, що ви будете досліджувати (описувати), яка користь компанії від реалізації проекту, які дані та ресурси вам необхідні, має бути розроблений календарний план робіт та опис результатів.

Крок 2




На другому етапі відбувається збір даних.

В завданні зазначено, які дані вам потрібні і де їх знайти.

На цьому етапі ви робите підготовку даних до такого стані, щоб вони могли бути використані в вашій системі. Це включає перевірку існування, якості та доступності даних.

Крок 3



В процес отримання даних можемо отримати помилки; на цьому кроці повинні підвищити якість даних і підготувати їх до подальшого використання.

Цей крок складається із трьох підкроків:

- чистка даних видаляє некоректні значення з джерела даних та усуває розбіжність між джерелами даних;
- трансформація даних гарантує, що дані знаходяться в потрібному форматі для використання в ваших моделях;
- інтеграція даних розширює інформацію шляхом поєднання інформації з кількох джерел

Крок 4

Data science process

1: Setting the research goal ⊕

2: Retrieving data ⊕

3: Data preparation ⊕

4: Data exploration ⊖

Simple graphs

Combined graphs

Link and brush

Nongraphical techniques

5: Data modeling ⊕

6: Presentation and automation ⊕


Дослідження даних спрямовано на розуміння даних.

На цьому кроці визначаємо кореляцію ознак, розподіл даних, знаходимо викиди в даних.

Можуть бути застосовані статистичні методи, відуалізація і побудова простих моделей

Цей крок часто називають "Exploratory Data Analysis" ("дослідницький аналіз даних")

Крок 5




На цьому кроці визначаємо тип моделі, відбираємо ознаки, які будуть використані для моделювання.

Також тут безпосередньо тренується модель і підбираються гіперпараметри моделі.


Проводиться оцінка якості моделі.

Крок 6



Завершене моделювання презентується замовнику. Може бути у вигляді презентації, ноутбуків із результатами моделювання, графіків, метрик, тощо.

CRISP-DM – Cross-Industry Standard




Словник термінів

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

Features
(attributes, measurements, dimensions)

Class labels
(targets)



Таргет, цільова змінна - колонка, в якій записано цільовий клас, прогнозоване значення

Фічі, атрибути, межери, діменшени, предіктори - колонки, за значеннями яких модель робить прогноз

Зразок, рядок, інстанс, спостереження, об'єкт - набір атрибутів і цільова змінна, що описують об'єкт

Мітка, актуальне значення - значення таргету або цифрове значення, яке має повернути модель для заданого об'єкта

MACHINE LEARNING VOCABULARY (SYNONYMS)

- **Target:** Response, Output, Dependent Variable, Labels
- **Features:** Predictors, Input, Independent Variables, Attributes
- **Example:** Observation, Record, Instance, Datapoint, Row
- **Label:** Answer, y-value, Category

Типи задач

Two Main Types of Machine Learning

	Dataset	Goal	Example
Supervised Learning	Has a target column	Make predictions	Fraud detection
Unsupervised Learning	Does not have a target column	Find structure in the data	Customer segmentation

TYPES OF MACHINE LEARNING

SUPERVISED

Data points have known outcome

UNSUPERVISED

Data points have unknown outcome

TYPES OF SUPERVISED LEARNING

REGRESSION

Outcome is continuous (numerical)

CLASSIFICATION


Outcome is a category

Задача регресії

X_1	X_2	X_3	Y
11	68.028164	0	21.46126
12	69.086446	0	23.28792
13	84.806730	1	18.71906
14	19.011313	1	18.50209
15	63.046323	1	22.37717
16	82.686964	1	24.19955
17	59.263664	1	20.64198
18	88.756598	0	29.50144
19	77.884304	1	24.49684
20	9.346073	0	27.15191


Задача класифікації

ID	Annual Income	Home Owner	Age	May Default
1	High	Yes	< 40	No
2	High	No	≥ 40	No
3	High	No	< 40	YES
4	Medium	Yes	≥ 40	No
5	low	No	≥ 40	No
6	Medium	No	≥ 40	No
7	Medium	Yes	≥ 40	Yes
8	Medium	No	< 40	Yes
9	High	No	≥ 40	No
10	Low	No	< 40	Yes



Precipitation	Humidity	Pressure	Temperature

Training Data



Output Labels

Training


Precipitation	Humidity	Pressure	Temperature

New Previously Unseen Input

Supervised Model

Predict

Predicted Label



SUPERVISED LEARNING OVERVIEW



TYPES OF UNSUPERVISED LEARNING

CLUSTERING

Identify unknown structure in data


DIMENSIONALITY REDUCTION

Use structural characteristics to simplify data

INTRODUCTION TO UNSUPERVISED LEARNING


Users of a web application:



- One feature (age)




- Five clusters









UNSUPERVISED LEARNING OVERVIEW



Типи машинного навчання



Шлях навчання

 LightGBM

PYTORCH

 NumPy

 dask


TensorFlow


NLTK

 pandas

 Keras

BeautifulSoup

 GENSIM
topic modelling for humans

 Scrapy

matplotlib



 CatBoost


plotly


scikit-learn

DMLC
XGBoost

spaCy

1. NumPy

2. Pandas

3. Matplotlib

4. TensorFlow

5. PyTorch

6. Scikit-learn

7. Requests

8. Keras

9. Seaborn

10. Plotly

11. NLTK

12. BeautifulSoup

13. Pygame

14. Gensim

15. spaCy

16. SciPy

17. Theano

18. PyBrain

19. Bokeh

20. Hebel

Додаткові курси

Machine Learning Crash Course (40+ exercises, 25 lessons, 15 hours)

<https://developers.google.com/machine-learning/crash-course/>

Введение в машинное обучение (Константин Воронцов, Evgeny Sokolov, 7 недель)

<https://www.coursera.org/learn/vvedenie-mashinnoe-obuchenie/home/welcome>

Machine Learning (Andrew Ng, 11 недель)

<https://www.coursera.org/learn/machine-learning/home/welcome>

Machine Learning A-Z™: Hands-On Python & R In Data Science (Kirill Eremanko, Hadelin de Ponteves, 41 час видео, 25 статей)

<https://www.udemy.com/machinelearning/>

